

Certiva — Ringkasan Metodologi & Hasil Benchmark

Hybrid Search v3 · Diuji 11 September 2026 · Dokumen ini dapat diakses bebas — tautkan langsung, tidak digerbang formulir.

1. Metodologi

Lingkungan uji: Windows-11-10.0.26200-SP0, Python 3.14.7. Korpus: 13 regulasi inti, diverifikasi manual terhadap sumber resmi (JDIH BPK/Kemenkeu) oleh jaringan praktisi hukum non-komersial (10 kantor notaris + 1 firma hukum). Rincian jumlah pasal dan relasi silang tidak dicantumkan sebagai angka statis di sini — angka tersebut dihitung langsung dari basis data & graph melalui tool MCP **corpus_stats** (lihat *Certiva — Ringkasan Tooling MCP*, Bagian 4), sehingga selalu konsisten dengan kondisi korpus terkini di setiap pemanggilan.

Definisi “first-try correct” (Precision@1): regulasi peringkat teratas yang dikembalikan mesin cocok persis dengan regulasi yang secara manual ditetapkan sebagai jawaban benar untuk query tersebut. Recall@5: regulasi yang benar muncul di 5 hasil teratas.

Set uji: 75 skenario regulasi nyata (7 kategori — lihat Bagian 3) + 28 query guardrail (di luar domain hukum, wajib mengembalikan hasil kosong). Skenario disusun & diverifikasi oleh praktisi hukum yang sama dengan jaringan ground-truth di atas.

Reproduksibilitas: laporan ini dihasilkan otomatis dari skrip benchmark yang menyematkan tanggal-jalan & versi kode secara otomatis pada setiap eksekusi, untuk memastikan angka yang dipublikasikan selalu tertaut pada versi sistem yang persis menghasilkannya.

2. Hasil Headline

97,3% Precision@1 (73/75)	98,7% Recall@5 (74/75)	15,1 ms Latensi Rata-rata	96,4% Guardrail Pass (27/28)
--	-------------------------------------	--	---

Seluruh angka diambil langsung dari benchmark produksi — bukan estimasi. RAM setelah model embedding dimuat: 798,2 MB.

3. Breakdown per Kategori Uji — Hybrid vs BM25-only

Kategori	N	Hybrid R@5	Hybrid P@1	BM25-only R@5	BM25-only P@1	Interpretasi
semantic_recovery	1	0/1	0/1	0/1	0/1	Satu-satunya uji murni dense-only; belum tervalidasi
disambiguation	6	6/6	6/6	6/6	6/6	Uji berat: pilih di antara regulasi bertopik berdekatan
regression	31	31/31	31/31	31/31	31/31	Cek tidak-ada-regresi (BM25 sudah benar sebelumnya)
regression_akronim	7	7/7	7/7	7/7	7/7	Akronim 1-kata wajib tidak diblokir gate
must_pass_akronim	14	14/14	13/14	14/14	13/14	False-negative check: akronim legit wajib non-kosong
must_pass_frasa	10	10/10	10/10	10/10	10/10	False-negative check: frasa pendek spesifik wajib non-kosong (naik dari 9/10 — lihat Bagian 6)
must_pass_regulasi	6	6/6	6/6	6/6	6/6	Nomor regulasi langsung wajib non-kosong

Catatan metodologi: sebagian besar kategori di atas adalah regression check (memastikan hybrid tidak merusak kasus yang sudah bekerja di BM25 murni), bukan bukti independen keunggulan lapisan semantic. Satu-satunya uji murni dense-only (semantic_recovery) belum berhasil — lihat Bagian 4.

Catatan sumber angka korpus: seluruh angka ukuran korpus (jumlah pasal, relasi antar-pasal, relasi antar-dokumen) yang dikutip di materi eksternal manapun — situs, deck, maupun dokumen ini — bersumber tunggal dari tool **corpus_stats** pada server Legal-Hybrid-Search, dihitung langsung dari basis data & graph saat tool dipanggil, bukan angka statis yang disalin antar-dokumen. Ini konsisten dengan kebijakan yang dinyatakan di *Certiva* — *Ringkasan Tooling MCP*, Bagian 4.

4. Keterbatasan yang Diungkap Jujur

3 item yang masih terbuka:

- **1 Precision@1 miss dari uji dense-only murni.** Query semantic-only murni (“kalau aplikasi startup error, siapa bisa dituntut?”) — hasil kosong, R@5 dan P@1 sama-sama gagal. Status: keterbatasan yang diterima sadar — kami memilih tidak melonggarkan filter penyaring query di luar domain hukum hanya demi satu kasus ini.
- **1 ambiguitas akronim** (bukan kegagalan; dua jawaban sama-sah relevan). “PPN” — regulasi benar masuk top-5, bukan #1.
- **1 kebocoran guardrail residual** dari 28 query di luar domain (pass rate 27/28 = 96,4%). “OTG buat transfer data hp” → salah muncul UU-27-2022. Root cause: tabrakan istilah sah (“transfer data” adalah istilah teknis yang memang dipakai UU PDP) dengan makna sehari-hari (USB OTG) — masih dievaluasi apakah query semacam ini sebenarnya relevan ditampilkan (bukan murni bug).

Item yang sudah tertutup sejak versi sebelumnya:

- 4 kebocoran guardrail yang dilaporkan di versi sebelumnya kini sudah tertutup (cara menanam cabai di pot, cara main catur, cara memperbaiki wifi, SKCK online) melalui perbaikan penyaringan kata generik pada lapisan pencarian kata kunci — divalidasi 0 regresi terhadap seluruh 103 skenario uji.
- 2 Precision@1 miss yang dilaporkan di versi sebelumnya kini tinggal 1. Kasus “PPh 22 Pihak Lain” tertutup melalui perbaikan pada algoritma penggabungan hasil pencarian kata kunci & semantic, tanpa menimbulkan regresi baru (divalidasi ulang terhadap seluruh 103 skenario, termasuk 3 skenario lain yang sempat terdampak pada iterasi perbaikan sebelumnya dan sudah dipulihkan).

Status lapisan semantic: kontribusi independennya (tanpa BM25) masih dalam validasi aktif — satu-satunya uji murni dense-only dalam test-set ini belum berhasil. Kami melaporkan ini secara transparan, bukan menyembunyikannya.

5. Reprodusibilitas & Kontak

Log lengkap skenario & query guardrail, beserta skrip pengujian, tersedia atas permintaan untuk juri dan investor. Ini adalah benchmark internal — laporan diri tim; verifikasi independen selalu kami sambut. Hubungi certiva@arsiva.tech atau kunjungi arsiva.tech.

6. Riwayat Revisi

Materi yang kami daftarkan pada CoCreate Pitch 2026 menggunakan data benchmark per **3 September 2026**: Precision@1 72/75 (96,0%), Guardrail Pass 23/28 (82,1%).

Sejak itu, tim melanjutkan siklus perbaikan & pengujian ulang sistem secara berkelanjutan. Dokumen ini merefleksikan hasil **TERBARU per 11 September 2026**, dengan angka:

- Precision@1: 72/75 → **73/75**
- Guardrail Pass: 23/28 → **27/28**

Kami memilih mempublikasikan versi terbaru ini secara transparan — termasuk mencatat perubahan sejak versi registrasi — karena percaya proses perbaikan yang teruji & terdokumentasi adalah bagian dari nilai yang ingin kami tunjukkan, bukan sesuatu yang perlu disamarkan.